算法概览图符号表

符号	英文含义	中文含义及其说明
t	timestep in real environment	在真实环境中的时间步
$\gamma \in [0,1]$	discount factor	折扣因子
k	hypothetical step	"假设步骤"是指为了考虑某种情况下可能的结果在模型中采取的假设性动作。
o_t	observation at timestep $\ t$	在时间步 t 的观测
u_t	reward at timestep t	在时间步 t 的奖励
a_t	action at timestep t	在时间步 t 的动作
s_t	hidden state at timestep t	在时间步 t 的 hidden state
r_t	predicted reward at timestep t	在时间步 t 的预测奖励
p	predicted policy logits	预测的策略logits
v	predicted value	预测的值
h	Representation Network	表征网络。 $s^0 = h(o^0)$ 是 the initial hidden state,
g	Dynamics Network	动力学网络。 $r^k, s^k = g(s^{k-1}, a^k)$
f	Prediction Network	预测网络。 $p^k, v^k = f(s^k)$
vp	predicted value prefix	预测的值前缀。仅在EfficientZero中使 用。
r_h^k	Reward hidden state at hypothetical step k	在假设步 k 的reward hidden state。 仅在EfficientZero中使用。
g^{rnn}	(recurrent) Dynamics Network	(循环)动力学网络。 $vp^k, s^k, r_h^k = g(s^{k-1}, a^k, r_h^{k-1})$ 。仅在EfficientZero中使用。
β	Proposal policy distribution	提议策略分布。仅在Sampled MuZero 中使用。

\hat{eta}	empirical policy distribution	经验策略分布。仅在Sampled MuZero中使用
$\tau = \{s_0, a_0, s_1, a_1,\}$	trajectory	轨迹
$R(\tau) = \sum_{t=1}^{T} r_t$	return	轨迹的奖励
$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k}$	Discounted return	回报(累计折扣奖励)
$\pi heta \left(a_t s_t ight)$	stochastic policy	随机性策略(其中 θ 是网络参数)
$V_{\pi}(s) \ = \ \mathbb{E}_{\pi}[G_t s_t = s]$	state value fuction	状态价值函数
$egin{aligned} Q_{oldsymbol{\pi}}(s,a) &= \ \mathbb{E}_{oldsymbol{\pi}}[G_t s_t=s,a_t=a] \end{aligned}$	state-action value fuction	动作价值函数

(表1: 算法概览图的符号说明。)